

# 時系列予測の作用素論的枠組み

手元にあるのは、有限個の時刻で観測された離散的な時系列である。この文書は、そのデータに対して経験的動的モデリング (EDM)、時系列統計、Koopman 解析、検索拡張予測が共通して何を計算しているのかを、力学系の定義から順に書き下したものである。

議論は一貫して二つの層に分けて進める。**理論層**は、データを生成する力学の上の理想化された対象を定義する層である。**推定層**は、その対象を有限のデータからどう近似するかの層である。中心となる主張は、理論層の一つの式に要約される。これらの分野の予測操作は、いずれも三つ組の選択

$$\left( \underbrace{u}_{\text{どの部分空間へ}}, \underbrace{h \in \mathcal{H}}_{\text{何を}}, \underbrace{n \in \mathbb{Z}}_{\text{いつの値を}} \right) \mapsto P_u U^n h$$

である。 $U$  は系が与える時間シフト作用素、 $P_u$  は解析者が選ぶ部分空間への直交射影である。分野の違いは、この三つ組の選び方 (4 節の軸 1) と、射影を有限標本からどう推定するか (軸 2、5 節) の違いに分解される。simplex projection、AR モデル、DMD、kNN-LM は同じ対象の異なる推定量である。

目的は二つある。第一に、各分野固有の語彙をこの共通の機械に翻訳し、同じ土俵で議論できるようにする。第二に、その翻訳が既存手法をどこまで説明し、どこから先が本文書独自の主張なのかを明示する。

出発点となる観察は、複数の分野が独立に同じ対象を指していることである。統計は条件付き期待値  $\mathbb{E}[Y | X = q]$  の推定と呼び、作用素論は Koopman 作用素を作用させた観測量の条件付き期待値と呼び、検索拡張予測はデータストア上の条件付き集約と呼ぶ。kernel analog forecasting については、測度保存かつエルゴード的な力学の下でこの条件付き期待値を一致推定することが示されている<sup>1</sup>。

構成は次の通り。1-3 節で理論層の機械を組み立て、4 節で設計空間を二軸に分解し、5 節で推定層を定式化する。ここまですが骨格である。6-9 節は EDM の慣習 (予測スキル  $\rho$ 、交差写像、S-map 係数、収束曲線) を両層の言葉に翻訳する実例集であり、10 節で隣接理論への接続、11 節で前提、12 節で語彙の対応を与える。

## 1. 力学系と観測量

この節の部品は、すべて観測量の空間に内積を入れるために置かれている。内積があれば角度と直交が定義でき、直交があれば射影が定義できる。以降の全議論は射影の幾何なので、ここが土台になる。

**力学系**として、可逆な測度保存変換の四つ組  $(M, \mathcal{B}, \mu, \Phi)$  を固定する。 $M$  は状態空間、 $\mathcal{B}$  はその可測集合の  $\sigma$  代数、 $\Phi: M \rightarrow M$  は可測かつ可逆な写像、 $\mu$  は  $\Phi$  の不変確率測度である。不変性は  $\mu(\Phi^{-1}A) = \mu(A)$  を意味する。さらに  $\Phi$  は  $\mu$  に関してエルゴード的とする。以下、 $(M, \mathcal{B})$  は標準 Borel 空間 (例えばコンパクト多様体や Polish 空間の Borel 構造) とし、 $\Phi$  は双可測な全単射とする。この仮定は命題 1 の逆作用素の可測性、命題 4 での Lusin–Suslin の定理の適用、Doob–Dynkin の補題の適用をまとめて正当化する。

<sup>1</sup>Alexander & Giannakis, *Operator-theoretic framework for forecasting nonlinear time series with kernel analog techniques*, Physica D (2020), arXiv:1906.00464. 一致性は標本数を無限大にした後に正則化を外す逐次極限であり、有限標本ではバンド幅と切断が本質的なバイアスを残す。アナログ予報そのものは Lorenz (1969) に遡る。

各部品の読み方を添えておく。 $\mu(A)$  の力学的な意味は、軌道が領域  $A$  に滞在する時間の割合である。決定論的な系に確率測度が現れるのはこのため、サイコロ的な無作為性は仮定していない。 $\mathcal{B}$  は積分を矛盾なく定義するために測る対象を指定するリストであり、以降「可測」の語は原則この但し書きの意味で現れる（例外は 7 節で、そこでは可測性が主役の概念になる）。 $\mu$  が確率測度 ( $\mu(M) = 1$ ) であることは、後で分散と相関を語るための規格化である。不変性は、 $A$  に流入する量と流出する量が釣り合っていること、すなわち滞在時間の分布が時間発展で変わらないことを述べている。

実データとの対応も先に述べておく。連続時間の系を観測間隔  $\tau_s$  でサンプリングする場合、 $\Phi$  はフローの time- $\tau_s$  写像である。このとき二つの注意が要る。フローがエルゴード的でも time- $\tau_s$  写像は例外的な  $\tau_s$ （フローの Koopman 固有振動数との共鳴）でエルゴード性を失いうること、および離散時間の固有値  $e^{i\omega\tau_s}$  からは  $\omega$  が  $2\pi/\tau_s$  を法としてしか同定できないこと（エイリアシング）である。 $\tau_s$  はしばしば解析者ではなく実験が決める。

観測量の空間を、二乗可積分な実数値関数のなす Hilbert 空間

$$\mathcal{H} := L^2(M, \mathcal{B}, \mu; \mathbb{R}), \quad \langle f, g \rangle = \int_M fg \, d\mu, \quad \|f\| = \langle f, f \rangle^{1/2}$$

とする。

**Koopman 作用素**を  $U : \mathcal{H} \rightarrow \mathcal{H}, Uf = f \circ \Phi$  で定める。

一見すると何もしていない定義だが、視点の入れ替えが起きている。状態の発展  $z \mapsto \Phi(z)$  は一般に非線形で扱いにくい。これに対し観測量の発展  $f \mapsto f \circ \Phi$  は、定義から直ちに線形である。有限次元の非線形力学を無限次元の線形作用素に取り替えるのが、この定義の取引である。

**命題 1.**  $U$  は等長である。 $\Phi$  が双可測な全単射なので  $U$  はユニタリであり、 $n \in \mathbb{Z}$  に対して  $U^n f = f \circ \Phi^n$  が定義される。

証明.  $\|Uf\|^2 = \int (f \circ \Phi)^2 \, d\mu = \int f^2 \, d(\Phi_*\mu) = \int f^2 \, d\mu = \|f\|^2$ 。不変性  $\mu(\Phi^{-1}B) = \mu(B)$  に  $B = \Phi A$  を代入すれば  $\Phi^{-1}$  も  $\mu$  を保存し、 $U^{-1}f = f \circ \Phi^{-1}$  が逆作用素を与える。□

不変性の役割はここにある。等長性は、時間をずらしても観測量の長さが変わらないこと、すなわち物差しが時間で伸縮しないことの保証である。これがなければ、時刻の異なる量の比較（予測誤差、相関）は意味を失う。

ユニタリ性から  $U^n$  の指数は整数全体を動く。負の冪  $U^{-\ell}$  は遅延、正の冪  $U^n$  は予測である。通常は特徴量の設計と予測という別のカテゴリに置かれる二つの操作が、同じ作用素の指数の符号違いになる。この統一が次節の読み枠の定義を支える。

実際に測定できる量は有限個の観測量  $g_1, \dots, g_d \in \mathcal{H}$  に限られる。観測される時系列は、ある軌道  $z_t = \Phi^t z_0$  に沿った値  $g_i(z_t)$  の列である。エルゴード性により時間平均が  $\mu$  に関する空間平均へ収束するので、有限標本から推定される量は  $\mu$  に関する量の推定になる。 $\mu$  は直接観測できないので、エルゴード性が理論とデータをつなぐ橋である（散逸系ではもう一本の橋が要る。11 節）。

## 2. 読み枠と部分空間

**読み枠**を、Koopman 作用素の冪で生成される観測量の有限列として定める。

$$u = (u_1, \dots, u_E), \quad u_j = U^{-\ell_j} g_{i_j} \in \mathcal{H}, \quad (i_j, \ell_j) \in \{1, \dots, d\} \times \mathbb{Z}$$

対応する評価写像を  $u : M \rightarrow \mathbb{R}^E, u(z) = (u_1(z), \dots, u_E(z))$  と書く。

軌道上では  $u_j(z_t) = g_{i_j}(z_{t-\ell_j})$  が成り立つ。これが遅延座標である。  $d = 1$  かつ  $\ell_j = (j-1)\tau$  とすれば古典的な遅延埋め込みになり、  $i_j$  を動かせば多変量埋め込みになる。時系列統計のラグ行列、Hankel 行列、検索拡張予測のコンテキスト窓は、いずれも同じ列の別名である。

この定義の要点は、遅延座標が特徴量の作り方ではなく、基底観測量が  $U$  の下で生成する族であることを明示する点にある。同じ族は Hankel-DMD や HAVOK の入力でもあり、Krylov 部分空間として扱われている<sup>2</sup>。

読み枠が生成する  $\sigma$  代数と閉部分空間を

$$\Sigma_u := \sigma(u) \subseteq \mathcal{B}, \quad \mathcal{H}_u := L^2(M, \Sigma_u, \mu) \subseteq \mathcal{H}$$

と書く。  $\Sigma_u$  可測な観測量とは、  $u$  の値だけから決まる観測量のことである。

### 仮説クラスの階層

生成元  $u_1, \dots, u_E$  を固定しても、推定に許す関数のクラスは一通りではない。制約の強い順に

$$\underbrace{\text{span}\{u_1, \dots, u_E\}}_{\text{線形包}}, \quad \underbrace{\text{span}\{\psi_1 \circ u, \dots, \psi_m \circ u\}}_{\text{有限辞書}}, \quad \underbrace{\mathcal{H}_K}_{\text{再生核 Hilbert 空間}}, \quad \underbrace{\mathcal{H}_u}_{\text{可測関数の全体}}$$

が並ぶ。AR モデルと DMD は線形包に留まり、ラグの線形結合しか許さない。EDMD と辞書法は基底を非線形な辞書に取り替える。Gauss 過程とカーネル法は再生核 Hilbert 空間を取る。EDM、  $k$  近傍回帰、検索拡張予測は右端におり、  $u$  の可測関数なら何でも許す。

ただしこの列は、文字通りの集合の包含としては読めない<sup>3</sup>。正確には、これは閉部分空間の階層ではなく、推定量に課す**仮説クラス**の強さの階層である。線形包と有限辞書のバイアスは部分空間の欠損から生じ、RKHS のバイアスは部分空間の欠損ではなくノルム球の制約（正則化）から生じる。

この階層が与える再解釈は一文にまとまる。**AR と EDM の違いは線形か非線形かではなく、同じ生成元にどれだけ強い仮説クラスを課すかである**。制約が強いほど表現できる関数が少なく、理論層の対象への近似誤差（バイアス）が増える。制約が弱いほど最良近似は真に近づき、有限標本からの推定は難しくなる（5 節で定量化する）。

以降、理論層では最も弱い制約  $\mathcal{H}_u$  を既定とする。

### 束構造

二つの読み枠の**連結**  $u \vee v$  を、列の連結として定める。このとき  $\Sigma_{u \vee v} = \sigma(\Sigma_u \cup \Sigma_v)$  であり、  $\mathcal{H}_u + \mathcal{H}_v \subseteq \mathcal{H}_{u \vee v}$  が成り立つ。読み枠の集合はこの演算で結び半束 (join-semilattice) をなす。生成される  $\sigma$  代数の側では交わりも定義できるが、それが読み枠から誘導される保証はないので、束として扱うのは  $\sigma$  代数の側である。変数を追加する操作（多変量埋め込み、Granger 型の入れ子比較）は、すべてこの半束の上を動く操作である。

## 3. 条件付き期待値作用素

中心となる対象は、  $\Sigma_u$  に関する条件付き期待値である。

$$P_u : \mathcal{H} \rightarrow \mathcal{H}_u, \quad P_u f = \mathbb{E}_\mu[f \mid \Sigma_u]$$

<sup>2</sup>Arbabi & Mezić (2017)、Brunton et al. (2017)、Kamb et al. (2020)。遅延座標を並べた Hankel 行列が、観測量から生成される Krylov 部分空間の基底を与える。

<sup>3</sup>Gauss 核の RKHS は非零の多項式（線形関数を含む）を一切含まないので  $\text{span}\{u_j\} \not\subseteq \mathcal{H}_K$  となりうる。また RKHS は  $L^2$  の閉部分空間ではなく、universal な核ではむしろ  $\mathcal{H}_u$  内で稠密であり、閉包を取ると右端に潰れる。Steinwart & Christmann, *Support Vector Machines* (2008)。

補作用素を  $Q_u := \text{Id} - P_u$  と書く。

**命題 2.**  $P_u$  は  $\mathcal{H}_u$  への直交射影である。すなわち線形であり、 $P_u^2 = P_u$ 、 $P_u^* = P_u$ 、 $\|P_u\| \leq 1$  を満たす。

これは条件付き期待値の  $L^2$  特徴づけそのものである。Doob-Dynkin の補題により、 $P_u f$  は  $\Sigma_u$  可測なので、可測関数  $F: \mathbb{R}^E \rightarrow \mathbb{R}$  が  $\mu$  に関してほとんど一意に存在して  $P_u f = F \circ u$  と書ける。アルゴリズムが実際に近似するのはこの代表  $F$  である。

これで冒頭の三つ組が定義できたことになる。

$$\left( \underbrace{u}_{\text{どの部分空間か}}, \underbrace{h \in \mathcal{H}}_{\text{何を予測するか}}, \underbrace{n \in \mathbb{Z}}_{\text{いつの値か}} \right) \mapsto P_u U^n h \in \mathcal{H}_u$$

$U$  は系から与えられ、 $P_u$  は解析者が選ぶ。選択の所在が式の中で分離されている。

## 4. 設計空間

推定の設計は二つの軸に分解される。

**軸 1: どの部分空間へ射影するか。** 2 節の仮説クラスの階層から一つを選ぶことに加え、生成元そのものの選択もこの軸に属する。埋め込み次元の選択、変数選択、multiview embedding、交差写像の向きは、すべて軸 1 の決定である。この軸は理論層の対象  $P_u U^n h$  を決め、決めた瞬間に近似誤差（バイアス）が決まる。

**軸 2: 射影を有限標本からどう推定するか。** 局所定数（simplex projection、アナログ予報、 $k$  近傍回帰、kNN-LM）、局所線形（S-map、LOESS）、カーネル法（kernel analog forecasting のスペクトル切断、GP-EDM のカーネルリッジ）、大域最小二乗（DMD、EDMD）が並ぶ。

| 手法                        | 軸 1（部分空間）                               | 軸 2（推定）               |
|---------------------------|-----------------------------------------|-----------------------|
| AR, VAR                   | 線形包                                     | 大域最小二乗                |
| DMD, EDMD                 | 有限辞書の張る空間                               | 大域最小二乗                |
| Hankel-DMD, HAVOK         | Krylov 部分空間                             | 大域最小二乗                |
| GP-EDM                    | RKHS（ノルム球制約）                            | カーネルリッジ               |
| kernel analog forecasting | RKHS（ノルム球制約）                            | カーネル法（スペクトル切断）        |
| simplex projection        | $\mathcal{H}_u$                         | 局所定数                  |
| S-map                     | $\mathcal{H}_u$                         | 局所線形                  |
| kNN-LM, kNN-MTS           | 一般化読み枠 $\psi \circ u$ の生成する $\sigma$ 代数 | 局所定数（負距離の softmax）    |
| 連結型時系列 RAG                | 一般化読み枠 $\psi \circ u$ の生成する $\sigma$ 代数 | 学習された融合（射影推定としては未定式化） |

下二行には二つの但し書きが要る<sup>4</sup>。第一に、学習されたエンコーダ  $\psi$  による特徴  $\psi \circ u$  は、Koopman 冪の族という 2 節の読み枠の定義からはみ出す。 $\sigma(\psi \circ u) \subseteq \Sigma_u$  なる部分  $\sigma$  代数

<sup>4</sup>kNN-LM は Khandelwal et al., *Generalization through Memorization* (ICLR 2020)。kNN-MTS はその時系列版 (IEEE TKDE 2025, arXiv:2505.11625)。連結型時系列 RAG は検索結果をカーネル平均せず、プロンプト連結や学習された融合モジュールで使う系統 (RAF, arXiv:2411.08249 ; TimeRAF, arXiv:2412.20810 など) で、条件付き期待値の局所推定として書けるかは自明でない。GP-EDM は Munch, Poynor & Arriaza (2017, Ecological Complexity)。

を生成するので枠組みの中には収まるが、 $\psi$  自体がデータから学習される点で、軸 1 が解析者の選択であるという前提が崩れる。軸 1 をデータで選ぶ操作は、埋め込み次元の交差検証や multiview embedding の選抜も含めて、5 節末尾で推定層の問題として扱う。第二に、kNN-LM が返すのは次の値の分布であって平均ではない。この点は 11 節（Markov 核）で回収する。

二つの軸は**独立に選択できる**。DMD と S-map の関係は、大域線形回帰と LOESS の関係にあたる。同じ射影を異なる方法で推定しているにすぎない。kNN-LM の負距離 softmax が simplex projection の指数重みと同じスロットに入ることも、両者が軸 2 の同じ行にいることの帰結である。ただし独立に選択できることと、統計的に独立であることは別である。軸 2 の推定の難しさは軸 1 の選択（特に  $E$  と仮説クラス）に支配される。この結合は 5 節で述べる。

新しい手法に出会ったときは、三つ問えば座標が決まる。どの部分空間へ射影しているか（生成元は何で、どの仮説クラスか）。有限標本からどう推定しているか。 $h$  と  $n$  は何か。この三問に答えられれば、手法は上の表のどこかに置ける。

既存の API はしばしば両軸の語を混ざっている。simplex\_projection( $X, Y, Q, k=E+1$ ) において  $E$  は軸 1 の選択、simplex は軸 2 の選択であり、種類の異なる決定が同じ関数の引数に並んでいる。

## 5. 推定層

ここまでの対象はすべて  $L^2(\mu)$  上の理想化である。手元にあるのは単一軌道のセグメント、すなわちデータ

$$\mathcal{D}_N = \{(u(z_t), (U^n h)(z_t))\}_{t=1}^N, \quad (U^n h)(z_t) = h(z_{t+n})$$

である。教師信号は時刻  $t+n$  の観測から得られる。経験測度を  $\mu_N := N^{-1} \sum_t \delta_{z_t}$  と書く。軸 2 の推定量は、クエリ  $q \in \mathbb{R}^E$  ごとの重み付き経験リスク最小化

$$\hat{F}_N(q) = \arg \min_{f \in \mathfrak{F}} \sum_{t=1}^N w_t(q) (f(u(z_t)) - (U^n h)(z_t))^2$$

という共通形に入る。 $\mathfrak{F}$  が定数関数で  $w_t$  が近傍指示または距離の指数重みなら simplex projection と  $k$  近傍回帰と kNN-LM。 $\mathfrak{F}$  がアフィン関数なら S-map と LOESS。 $\mathfrak{F}$  が RKHS のノルム球（リッジ罰則）なら GP-EDM と kernel analog forecasting。 $w_t \equiv 1$  かつ  $\mathfrak{F}$  が線形なら AR と DMD。軸 2 とは  $(\mathfrak{F}, w)$  の選択のことである。対応する作用素の推定量を  $\hat{P}_u^{(N)}$  と書く。

### 一貫性と収束レート

$\hat{P}_u^{(N)} \rightarrow P_u$  は、エルゴード性だけでは従わない。Birkhoff の定理はレートなしの各点収束であり、収束が任意に遅い系が存在する。局所推定量の一貫性と収束レートには、軌道の混合性（mixing）が別途必要である<sup>5</sup>。12 節の表にある Theiler window はこの従属性の症状への対処であり、理論層では混合仮定として現れる。

レートは仮説クラスに強く依存する。線形包なら誤差は  $\sqrt{E/N}$  程度で済むのに対し、 $\mathcal{H}_u$  レベルの完全ノンパラメトリック推定は  $N^{-2/(4+E)}$  程度に劣化する（次元の呪い）。最も弱い制約を選ぶことの代償は、 $E$  に対する指数的な標本要求として定量化される。生態学で典型的な  $N \approx 30-100$  の系列で大きな  $E$  を取る完全ノンパラメトリック推定はレートの正当化しがたい、という実務感覚はこの言い換えである。4 節の二軸が統計的には独立でないというのは、この意味である。

<sup>5</sup>Masry (1996) が混合条件下の局所多項式回帰の一貫性とレートを与える。kernel analog forecasting のエルゴード論的一貫性 (Alexander & Giannakis 2020) はスペクトル切断を用いた特定の推定量への結果であり、局所推定量一般には転移しない。

## リーク

遅延窓は重なり合うので、隣接する標本  $u(z_t), u(z_{t+1})$  はほぼ同一である。クエリ  $q = u(z_s)$  の近傍を全データから取ると、時間的に隣接する点が近傍として選ばれ、予測スキルは系列相関の自己再生産で水増しされる。Theiler window ( $|t - s| \leq w$  の除外) はこのリークの除去であり、機械学習の purged/embargoed 交差検証、hv-block 交差検証と同じ操作である<sup>6</sup>。理論層の言葉では、経験近傍平均が  $\mathbb{E}[\cdot | \Sigma_u]$  ではなく「同一軌道セグメントの条件付き平均」を推定してしまうことの防止である。

## 軸 1 の選択も推定である

実務では読み枠自体をデータで選ぶ。 $\tau$  は自己相関の最初のゼロ交差か平均相互情報量の最初の極小 (Fraser & Swinney 1986)、 $E$  は偽近傍法 (Kennel et al. 1992) か予測スキルの交差検証で選ばれる。multiview embedding の選抜、エンコーダの学習も同じ操作である。軸 1 をデータで選ぶことは二軸のどちらでもない第三の層をなし、選抜に使ったスキルの楽観 (選択バイアス) という固有のリークを持つ。また、同じ  $\Sigma_u$  を生成する読み枠どうしても有限標本での推定の条件数は大きく異なる。理論層で等価な軸 1 の選択が、推定層では等価でない。

## 6. 予測とスキル

ここからの四つの節は、この機械が EDM の慣習をどう説明するかの実例である。

**命題 3 (最良近似)** .  $P_u U^n h$  は  $\mathcal{H}_u$  の中で  $U^n h$  への  $L^2$  最良近似である。

$$P_u U^n h = \arg \min_{f \in \mathcal{H}_u} \|U^n h - f\|$$

simplex projection、S-map、GP-EDM、kernel analog forecasting は、いずれも代表  $F$  の推定量である。違いは推定の方法にあり、推定される対象は共通する。

**命題 4 (埋め込み定理の位置づけ)** . 可測写像  $v: \mathbb{R}^E \rightarrow M$  が存在して  $v \circ u = \text{id}_M$  が  $\mu$ -a.e. 成り立つならば、 $\Sigma_u = \mathcal{B} \pmod{\mu}$  が成り立ち、したがって  $P_u = \text{Id}$  となる。 $M$  が標準 Borel 空間で  $u$  が  $\mu$ -零集合を除いて単射ならば、この  $v$  は常に存在する (Lusin-Suslin の定理)。

埋め込み定理はこの仮定を保証する条件を与える。 $M$  がコンパクト  $C^2$  多様体 (次元  $m$ ) のとき、Takens (1981) は generic な  $(\Phi, g)$  に対して  $E = 2m + 1$  の遅延写像が埋め込みになることを示した。Sauer-Yorke-Casdagli (1991) は条件を  $E > 2 \text{boxdim}(A)$  ( $A$  はアトラクタ) と周期点の条件に置き換え、prevalent な観測量に対して同じ結論を与えた。本枠組みで必要なのは埋め込みより弱い  $\mu$ -a.e. 単射性であり、これには  $E > \dim_H \mu$  (Hausdorff 次元、二倍は不要) で足りることが知られている<sup>7</sup>。いずれの場合も、帰結は  $P_u = \text{Id}$  という一つの等式になる。

ただしこの等式は観測ノイズの前では脆い。ノイズがあるとき遅延ベクトルは状態の関数でなく、 $P_u = \text{Id}$  は厳密には成立しない。ノイズ下では埋め込みの忠実性は  $0/1$  ではなく、ノイズ増幅率として  $(\tau, E)$  に依存して連続的に劣化する (Casdagli et al. 1991)。

<sup>6</sup>Theiler (1986, Phys. Rev. A)。金融 ML の purging/embargo は López de Prado (2018)、hv-block は Racine (2000, J. Econometrics)。

<sup>7</sup>Barański, Gutman & Śpiewak, *A probabilistic Takens theorem*, Nonlinearity 33 (2020)。測度論的な設定では必要な遅延数が半減することは、 $\mu$ -a.e. の単射性で十分という本文書の設計を裏書きする。

EDM は予測スキルを Pearson 相関  $\rho$  で測る慣習を持つ。この慣習は射影の幾何から説明できる。以下、 $h$  は中心化されているとする。測度保存性から  $\int U^n h d\mu = \int h d\mu = 0$  であり、条件付き期待値の性質から  $\int P_u U^n h d\mu = 0$  も従うので、両者とも中心化されている。

**命題 5 (相関は角度の余弦である) .  $P_u U^n h \neq 0$  のとき**

$$\text{corr}(U^n h, P_u U^n h) = \frac{\|P_u U^n h\|}{\|U^n h\|} = \cos \angle(U^n h, \mathcal{H}_u)$$

証明.  $P_u$  の自己共役性と冪等性から  $\langle U^n h, P_u U^n h \rangle = \langle P_u U^n h, P_u U^n h \rangle = \|P_u U^n h\|^2$ 。これを相関の定義に代入する。□

直交射影に対する三平方の定理

$$\|U^n h\|^2 = \|P_u U^n h\|^2 + \|Q_u U^n h\|^2$$

を併せると、 $\rho^2 = 1 - \|Q_u U^n h\|^2 / \|U^n h\|^2$  が得られる。 $\rho^2$  は  $U^n h$  のうち  $\mathcal{H}_u$  で説明される分散の割合である。

この等式は厳密な射影に対する理想化であり、有限標本の推定量に対しては成り立たない。推定量は射影ではないので、予測値の尺度の誤り（較正誤差）は  $\rho$  に現れない。 $\rho$  はケースごとの損失に分解できない標本要約統計であり、アフィン変換で不変なので、条件付き・無条件バイアスを検出しない (Murphy 1988 の MSE 分解)。点予測の評価として正しい枠組みは consistent scoring function (Gneiting 2011) であり、 $\rho$  はいかなる汎関数に対しても consistent でない。固有スコアリング則 (proper scoring rule) は予測分布に対する概念なので、その議論は 11 節の Markov 核の層に属する。

ホライズン  $n$  への依存も二層に分けて読める。理論層では、 $h$  の混合的（連続スペクトル）成分について任意の固定した  $f \in \mathcal{H}_u$  との相関  $\langle U^n h, f \rangle$  が  $n \rightarrow \infty$  で減衰する一方、点スペクトル成分は減衰しない。推定層では、 $P_u = \text{Id}$  の決定論的カオスであっても、初期誤差が最大 Lyapunov 指数で増幅されるためスキルはホライズンとともに落ちる。EDM が  $\rho(T_p)$  の減衰を決定論的カオスの証拠に使う慣習 (Sugihara & May 1990) は、この二層の合成を見ている。

## 7. 交差写像

CCM は、原因側の観測量を結果側の読み枠から復元できるかを問う。

**命題 6 (交差写像は部分空間への所属を測る) .  $x \in \mathcal{H}$  を中心化されたノルム非零の観測量、 $u_Y$  を別の変数から作った読み枠とし、スキルは Pearson 相関で測るとする。交差写像スキルの理想極限は  $\cos \angle(x, \mathcal{H}_{u_Y})$  であり、**

$$\text{skill} = 1 \iff x \in \mathcal{H}_{u_Y} \iff x \text{ が } \Sigma_{u_Y} \text{ 可測な関数と } \mu\text{-a.e. 一致}$$

「理想極限」には推定層の仮定が畳み込まれていることに注意する。すなわち交差写像の推定量が  $P_{u_Y} x$  に  $L^2$  一致することを仮定しており、これは 5 節の条件（エルゴード性に加えた混合性）を要する。

CCM の非対称性は、部分空間の包含関係の非対称性そのものである。 $x \in \mathcal{H}_{u_Y}$  は  $y \in \mathcal{H}_{u_X}$  を含意しない。因果という語を使わずに、測定している量を述べることができる。

この命題は本文書の定式化であり、既存文献に確立された翻訳ではない。Koopman 作用素を用いた因果探索自体は近年提案されているが<sup>8</sup>、CCM をこの形（条件付き期待値部分空間への所属）に翻訳した文献は、調査した範囲では見当たらなかった。

Granger 型の問いは、同じ半束の上の別の命題として書ける。

$$\text{CCM: } \|Q_{u_Y}x\| \quad \text{Granger 型: } \|Q_{u_Y}Uy\| \text{ と } \|Q_{u_Y \vee u_X}Uy\| \text{ の比較}$$

CCM は  $x$  が  $\mathcal{H}_{u_Y}$  に既に属するかを問い、Granger 型は読み枠を連結して部分空間を広げたときに残差が減るかを問う。両者は問う位置が異なるだけで、どちらも読み枠が生成する部分空間の半束の上の命題である。なお Granger 型の式は一期先 ( $n = 1$ ) の場合である。三変数以上の系では一期先の非因果性は多段先の非因果性を含意しないので (Dufour & Renault 1998)、 $n$  を動かすなら別の命題になる。

この形にすると、派生手法も同じ枠に収まる。

- **UIC** : Granger 型と同型の入れ子比較であり、残差を  $L^2$  ノルムではなく Kullback-Leibler 情報量で測る。
- **PCM** : 第三の読み枠  $u_Z$  に対して  $Q_{u_Z}$  を先に施してから角度を測る。偏相関が直交補空間への射影であることの直接の反映である。

## 8. 局所線形化

$P_u U^n h = F \circ u$  の代表  $F: \mathbb{R}^E \rightarrow \mathbb{R}$  が点  $q$  で微分可能なとき、その微分  $DF(q)$  を考える。S-map の係数はこの  $DF$  の推定である。局所定数の当てはめは傾きの係数を持たないため、回帰係数として  $DF$  を読み取るには次数一以上の局所多項式が必要になる (Fan & Gijbels 1996) <sup>9</sup>。

**命題 7.**  $DF$  は  $U^n$  の微分ではなく  $P_u U^n$  の微分である。

$P_u = \text{Id}$  が成り立つとき、 $F = (U^n h) \circ u^{-1}$  となり、 $DF(q)$  は読み枠を座標に取った表示での  $h \circ \Phi^n$  の微分になる。真のヤコビアンとは座標変換  $Du$  を挟んで共役の関係にある。

$P_u \neq \text{Id}$  のときは、この関係すら成り立たない。 $DF$  は射影された関数の微分にとどまる。

生態学の文献で相互作用ヤコビアンと呼ばれている量を力学のヤコビアンと同一視するには、埋め込みの忠実性が要る。この但し書きは枠組みから自動的に出る。6 節で述べた通り観測ノイズは忠実性を連続的に劣化させるので、実データの S-map 係数は常にこの但し書きの下にある。

## 9. 収束

CCM はライブラリのサイズを変えたときのスキルの推移を証拠に使う。

5 節の記法で、ライブラリサイズ曲線は  $\hat{P}_u^{(N)} \rightarrow P_u$  という作用素推定の学習曲線である。

したがって収束は  $\Sigma_{u_Y}$  可測性の証拠ではなく、推定量の一致性の現れである。実際、共有された季節駆動の下では相互作用のない系でもスキルはライブラリサイズとともに上昇し、CCM は誤って影響を検出する (Cobey & Baskerville 2016)。ノイズと外部影響の下で収束が非単調に劣化することも報告されている (Mønster et al. 2017)。Sugihara et al. (2012) 自身が収束の機構を「ライブラリの増加で近傍が密になり推定誤差が減ること」に帰しており、本節の主張はその機構説明の帰結を

<sup>8</sup>例えば Koopman 表現上で因果構造を推定する系統 (arXiv:2410.10103、Communications Physics 2025 など)。

<sup>9</sup>微分の推定自体は局所定数平滑化の解析的微分でも一致的に可能であり、局所多項式の利点は係数として直接読めることとバイアス特性にある。正則化つき S-map は Cenci, Sugihara & Saavedra (2019, Methods Ecol. Evol.)。



負の側から述べたものにあたる。さらに5節の通りエルゴード平均には普遍的な収束レートがないので、収束の「速さ」からも結論は引き出せない。スキルの水準が上がる要因は可測性以外にも多くあるので、収束の観測だけでは命題6の右辺を結論できない。CCMの既知の弱点が、この枠組みでは推定層と理論層の混同として位置づけられる。

## 10. 拡張の余地

### 閉包と記憶項

$P_u$  と  $U$  は交換しない。  $\text{Id} = P_u + Q_u$  を繰り返し挿入すると、離散時間の Mori-Zwanzig 分解が得られる。

$$U^n = \sum_{m=0}^{n-1} U^{n-1-m} P_u U (Q_u U)^m + (Q_u U)^n$$

$m = 0$  の項が Markov 項、 $m \geq 1$  の項が記憶項、最後の項が直交項である。

遅延座標を増やす操作は、記憶項を Markov 項に吸収する操作にあたる。埋め込み定理の条件が満たされるとき（命題4）直交項と記憶項の寄与が消えて発展が単一の Markov 項に帰着することは、この枠組みからの帰結として読める。これは本文書の観察であり、この形の定理として述べた文献は調査した範囲では見当たらない<sup>10</sup>。EDMにおける埋め込み次元の選択は閉包問題であり、記憶核と粗視化の理論がそのまま利用できる。

### 部分空間の半束

写像  $u \mapsto \mathcal{H}_u$  は、読み枠の半束から閉部分空間の族への写像である。連結  $\vee$  が使えるので、因果ネットワークの推定を  $\sigma$  代数の束の構造推定として定式化できる。multiview embedding は、候補読み枠を標本内スキルで順位付けして上位  $\lfloor \sqrt{m} \rfloor$  個を選び、各読み枠の単一最近傍推定を平均する操作であり（Ye & Sugihara 2016）、理想化すれば選抜された  $\{P_{u_j}\}$  の凸結合にあたる。射影の凸結合は射影ではないこと、選抜自体が5節の「軸1の推定」であることに注意する。条件付き独立性は束の中の直交関係である。

### スペクトル

有限辞書の張る空間  $\mathcal{D}$  への直交射影を  $P_{\mathcal{D}}$  と書くと、EDMD 行列は標本数無限大の極限で圧縮  $P_{\mathcal{D}} U|_{\mathcal{D}}$  に収束し、DMD 固有値はこの有限次元圧縮の固有値である（Korda & Mezić 2018）。 $\mathcal{H}_u$  上の圧縮  $P_u U P_u$  はその辞書無限大極限にあたるが、固有値の収束は一般には成り立たず（スペクトル汚染）、対処にはユニタリ性を保つ圧縮や残差による検証が要る<sup>11</sup>。DFの固有値は圧縮スペクトルの局所版にあたる。時変ヤコビアン固有値を用いた動的安定性の解析は、その局所版を見ていると述べられる。

### 確率的な系

$P_u$  は条件付き期待値なので、決定論性を仮定していない。過程ノイズは  $P_u \neq \text{Id}$  として最初から枠内にある。観測ノイズはより注意が要る。ノイズの乗った遅延ベクトルは  $M$  上の関数ではないので、正確には軌道空間とノイズ空間の積という拡大確率空間の上の条件付き期待値になる。

<sup>10</sup>離散時間 Mori-Zwanzig と Koopman 学習の接続は Lin, Tian, Livescu & Anghel, SIAM J. Appl. Dyn. Syst. (2021), arXiv:2101.05873. Mori-Zwanzig モード分解と時間遅延埋め込みの数値的比較は arXiv:2311.09524（ただし同論文は両者を対置しており、等価性を証明していない）。

<sup>11</sup>mpEDMD (Colbrook 2023, SIAM J. Numer. Anal.)、ResDMD 系。

## 11. 前提と適用範囲

**不変測度と定常性を仮定している。** 不変測度の存在自体は強い仮定ではない。コンパクトな状態空間と連続な写像があれば不変確率測度は存在し (Krylov-Bogolyubov)、散逸系もアトラクタ上に舞台を移せば入る。ただし観測軌道の時間平均が  $\mu$  の空間平均に収束するには、 $\mu$  が物理 (SRB) 測度であるという追加仮定が要る。エルゴード性は  $\mu$ -a.e. の初期値しか保証せず、Lebesgue 的に選ばれた初期値には及ばない。強い仮定は定常性のほう、すなわちアトラクタ上の統計だけに興味を限ることである。過渡現象そのものが対象である場合や、外部強制とパラメータ漂流で  $\Phi$  自体が変わる場合には、固定した  $\mu$  が存在せず、 $L^2(\mu)$  の上で議論する本枠組みの外にある。仮定が破れてもアルゴリズムは数値を返すことに注意する。失われるのは数値の意味づけ ( $\rho$  が角度である、収束が一致性である、といった解釈) のほうである。

**可逆性を仮定している。** 読み枠は  $U^{-\ell}$  を使うので  $\Phi$  の可逆性が本質的に効いている。非可逆な系 (一次元の単峰写像、ノイズ駆動系) では、自然拡大ないし両側シフト空間に持ち上げてから枠組みを適用する。

**理論層と推定層を分ける。**  $P_u$  は  $L^2(\mu)$  上の射影であり、simplex projection と S-map は有限標本上のアルゴリズムである。後者は前者の近似であって射影ではない。elastic net で正則化した S-map や、ハイパーパラメータを周辺尤度で推定する Gauss 過程は、予測対象に依存するので観測量について線形ですらない。

**条件付き期待値は平均のみを扱う。** 予測分布や分位点を扱うには、 $P_u$  を Markov 核へ一般化する必要がある。GP-EDM と UIC が実質的にそこにいる。kNN-LM もここに置ける。 $h$  を値の指示関数の族  $\{1[y = v]\}_v$  と取れば  $P_u U 1[y = v]$  が条件付き確率になるので、分布の推定も指示関数の平均としては  $L^2$  層に収まる。失われるのは分布としての較正と固有スコアリング則の議論であり、それは Markov 核の層に属する。ただし核へ一般化すると  $L^2$  の幾何 (角度と三平方の定理) を失うので、二層に分けて保持するのが妥当だと考える。

## 12. 語彙の対応

| EDM                   | 時系列統計                         | Koopman 解析                     | 検索拡張予測                     |
|-----------------------|-------------------------------|--------------------------------|----------------------------|
| 遅延埋め込み, SSR           | ラグ行列, Hankel 行列               | Krylov 部分空間                    | クエリエンコード, コンテキスト窓          |
| library               | 学習集合                          | データ行列                          | データストア                     |
| prediction set        | 検証集合                          |                                | クエリ集合                      |
| Theiler window        | purging, embargo, hv-block CV |                                | 自己リーク除去                    |
| simplex projection    | $k$ 近傍回帰, アナログ予報              | kernel forecasting      analog | kNN-LM, kNN-MTS            |
| 重み $\exp(-d/d_{(1)})$ | 適応バンド幅の指数カーネル                 |                                | 負距離の softmax <sup>12</sup> |

<sup>12</sup>対応は形のみで、適応性の所在が異なる。simplex projection は最近傍距離  $d_{(1)}$  によるクエリごとの正規化を持つが、kNN-LM の原型は正規化なし・温度 1 固定である (Khandelwal et al. 2020)。温度の調整はむしろ後続研究の発見 (Xu, Alon & Neubig 2023) で、それも固定値のチューニングであり適応ではない。したがって  $\theta$  の行の対応物は原型には存在しない。

| EDM                 | 時系列統計                      | Koopman 解析  | 検索拡張予測                      |
|---------------------|----------------------------|-------------|-----------------------------|
| S-map               | LOESS, 局所線形回帰              | 局所線形近似      | 検索後の局所モデル当てはめ               |
| $\theta$            | バンド幅の逆数                    |             |                             |
| S-map 係数            | 局所回帰係数                     | 有限時間ヤコビアン   | 局所サロゲートの係数                  |
| $T_p$               | 予測ホライズン, direct multi-step | $U^n$ の指数   | 予測長                         |
| generateSteps       | iterated multi-step        | $U$ の反復適用   | 自己回帰デコード                    |
| $\rho$              | 相関スキル                      | 部分空間との角度の余弦 |                             |
| CCM                 | 関数従属性の検定                   | 部分空間への所属    | クロスモーダル検索                   |
| 収束                  | 学習曲線                       | 作用素推定の一致性   | データストアのスケーリング <sup>13</sup> |
| surrogate           | 制約付きリサンプリング・無作為化検定         |             |                             |
| multiview embedding | 特徴部分集合のアンサンブル              | 辞書の選択       | 上位選抜つきアンサンブル                |

翻訳しきれず残るものは三つある。

1. 遅延座標を状態の忠実な複製とみなす主張。標準的な時系列の機械学習はラグ窓を特徴として使うだけで、それが状態と同型だとは主張しない。命題 4 の  $P_u = \text{Id}$  がこの主張にあたる。
2. 交差写像の向き。結果側の再構成から原因側を復元するという向きは、決定論的な結合系に特有である。
3. 収束を証拠として使うこと。機械学習において学習曲線は診断の道具であって検定統計量ではない。

## 未決の設計判断

- 中心対象を  $P_u$  とするか  $P_u U^n$  とするか。  $U$  は系から与えられ  $P_u$  は解析者が選ぶので、選択の所在が分離される前者を推す。
- 読み枠を観測量の有限族として定めるか、写像  $M \rightarrow \mathbb{R}^E$  として定めるか。連結  $\vee$  が自然に入り半束構造が使える前者を推す。
- $L^2$  の層に留めるか、Markov 核の層まで上げるか。二層で保持する案を第 11 節に述べた。
- 学習されたエンコーダ  $\psi \circ u$  を読み枠の一般化として定義に含めるか。  $\sigma(\psi \circ u) \subseteq \Sigma_u$  として枠内には収まるが、Koopman 冪の族という定義の輪郭は失われる。含めるなら「一般化読み枠」として区別する案を推す。
- 連結型の検索拡張予測（検索結果をプロンプトに連結する系統）を射影の推定として定式化できるか。現状では開問題として残す。

<sup>13</sup>kNN-LM はデータストアを 3B トークンまで拡大すると perplexity が単調に改善する (Khandelwal et al. 2020, Fig. 2a)。Shao et al. (NeurIPS 2024) のデータストア・スケーリング則も同型の学習曲線である。